

Multidimensionale Evaluation LLM-basierter Coding-Agenten jenseits funktionaler Testmetriken

Chris David Kaufmann · Luca di Siro · Daniel Ertel · Richard Beser | DHBW Mosbach | Wirtschaftsinformatik

Research in Progress
Student Challenge

99,7–100,0 %
sichtbare Tests

79,3–92,9 %
Hidden Tests


3.870–7.489
Tokens/Testfall

Sichtbare Tests zeigen einen Ceiling-Effekt - die zusätzliche Metrikschicht macht die Unterschiede sichtbar.

1 Studiendesign & Metrik

288 gepaarte Läufe
3 Agenten · 4 Aufgaben × 4 Varianten
3 Prompt-Stufen · 2 Modi

Evaluationspipeline



Metrikschicht · sechs Perspektiven

Funktionalität	sichtbare Tests
Robustheit	verdeckte Randfälle
Wartbarkeit	SLOC · Komplexität · MI
Minimalität	angemessener Codeumfang
Constraint	Regeln · Testdatei
Effizienz	Laufzeit · Tokens

Qualitativer Gesamtscore

$$Q = \frac{\text{Interface} + \text{Constraint} + \text{Minimality} + \text{Robustness}}{4}$$

* Interface = Schnittstellenvorgabe eingehalten.

Token-Normalisierung

Prompt/Cache + Completion + Reasoning

Statistik

Friedman/Cochran-Q · Wilcoxon/McNemar · Holm

Faire Artefaktbasis: n = 70

n = 70: Artefakte aller drei Agenten.
n = 96 je Agent: operative Vollauswertung.

2 Zentrale Ergebnisse

Sichtbare Tests: Ceiling

Claude 100,0 % · Gemini 100,0 % · Codex 99,7 %
global p = 0,368


Hidden-Pass-Rate

höher ist besser



Tokens je bestandenen Testfall

niedriger ist besser




Qualitativer Gesamtscore



alle Paarvergleiche Holm-korrigiert signifikant

Prompt-Qualität ↓ Tokens



3 Hypothesen & Fazit

Hypothesenprüfung

H1 Token-Sättigung **ANGENOMMEN**
Mehr Tokens erklären keine höhere Leistung. p = 0,913; Hidden-Pass-Rate: p = 0,476

H2 Self-Refining **ABGELEHNT**
Kein Robustheitsgewinn: Direct 85,6 % vs. Self-Refining 84,8 %; p = 0,179

H3 Prompt-Qualität **ANGENOMMEN**
Tokenverbrauch sinkt: 107.045 → 101.888 → 93.262; p = 0,0409

H4 Prompt-Qualität **ABGELEHNT**
Kein zusätzlicher Qualitätsgewinn; p = 0,990

Kein universelles Ranking

Claude höchste Qualität · Hidden-Pass 92,9 %

Codex beste Effizienz · geringste Komplexität

Gemini operativ stabil · Compliance 75,7 %

TAKE-AWAY

FUNKTIONAL KORREKT IST NICHT MEHR GENUG.

Die Bewertungspriorität im Software Engineering verschiebt sich von funktionaler Korrektheit hin zu Qualität, Robustheit und Effizienz.